

第三章 线性模型

一、填空题

1. 生成模型通过估计 (类条件概率) 进行分类, 判别模型通过估计 (后验概率) 进行分类。
2. 感知器算法通常采用 (梯度下降) 法求解目标函数的优化问题。
3. 线性回归模型的封闭解又称为 (最小二乘) 解。
4. 逻辑回归函数的取值区间是 $((0, 1))$ 。

二、判断题

5. 当两个类别均服从正态分布时, 根据贝叶斯决策理论计算出的决策面必然是一个线性决策面。 (×)
6. 当两个类别均服从正态分布时, 根据贝叶斯决策理论计算出的决策面必然是一个二次型决策面。 (×)
7. 线性回归模型如存在唯一解, 必然可以令模型在训练集上的均方误差为 0。 (×)
8. 4 个不具有共线性的三维样本, 无法用线性回归模型得到唯一解。 (×)
9. 逻辑回归模型无法用于多类分类问题。 (×)

三、选择题

10. 假设线性回归问题的训练集为: $\mathbf{x}_i \in \mathbb{R}^3, i = 1, \dots, 100$, 则该线性模型包含多少个参数: (B)
A. 3 个 B. 4 个 C. 100 个 D. 101 个
11. 上题中如果使用线性回归的最小二乘解的封闭解形式, 则自相关矩阵 R_x 的大小为: (B)
A. 3×3 B. 4×4 C. 100×100 D. 101×101
12. 逻辑回归模型中的逻辑回归函数可以看作是对以下哪种概率的描述: (B)
A. $p(x|\omega_1)$ B. $p(\omega_1|x)$ C. $p(x)$ D. $p(\omega_1)$

四、简答题

13. 请写出感知器算法的目标函数的标准数学形式, 并解释其中每一个符号的意义与计算方法, 说明其合理性。

答:

$$J(\hat{\mathbf{w}}) = \sum_{\mathbf{x} \in \Omega(\hat{\mathbf{w}})} \delta_x \hat{\mathbf{w}}^T \hat{\mathbf{x}}$$

其中:

$$\delta_x = \begin{cases} -1 & \mathbf{x} \in \omega_1 \\ 1 & \mathbf{x} \in \omega_2 \end{cases}$$

当样本被错分类时两种情况:

- 实际属于 ω_1 , 被错分 ω_2 : $\hat{\mathbf{w}}^T \hat{\mathbf{x}} < 0$, $\delta_x = -1$
- 实际属于 ω_2 , 被错分 ω_1 : $\hat{\mathbf{w}}^T \hat{\mathbf{x}} > 0$, $\delta_x = 1$

当存在错误样本时, $\delta_x \hat{\mathbf{w}}^T \hat{\mathbf{x}}$ 总是一个整数, 因此减少错误样本有利于减少目标函数 $J(\hat{\mathbf{w}})$ 。

14. 请写出线性回归模型的封闭解数学形式, 及其推导过程, 并标明符号意义。

解: 线性回归模型封闭解是对代价函数求导等于0 的方程求解得到的结果。

代价函数为:

$$J(\hat{\mathbf{w}}) = \mathbb{E}[(y - f(\mathbf{x}))^2] = \mathbb{E}[(y - \hat{\mathbf{w}}^T \hat{\mathbf{x}})^2] \approx \frac{1}{N} \sum_{n=1}^N (y_n - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_n)^2$$

代价函数求导为零, 列方程如下:

$$\begin{aligned} \frac{\partial J(\hat{\mathbf{w}})}{\partial \hat{\mathbf{w}}} &\approx \frac{2}{N} \sum_{n=1}^N [-\hat{\mathbf{x}}_n (y_n - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_n)] = \frac{2}{N} \sum_{n=1}^N [(\hat{\mathbf{x}}_n \hat{\mathbf{x}}_n^T) \hat{\mathbf{w}} - \hat{\mathbf{x}}_n y_n] = 0 \\ \left[\sum_{n=1}^N \hat{\mathbf{x}}_n \hat{\mathbf{x}}_n^T \right] \hat{\mathbf{w}} &= \sum_{n=1}^N \hat{\mathbf{x}}_n y_n \end{aligned}$$

令:

$$X = \begin{bmatrix} \hat{\mathbf{x}}_1^T \\ \hat{\mathbf{x}}_2^T \\ \vdots \\ \hat{\mathbf{x}}_N^T \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

将其带入方程, 可以得到:

$$(X^T X) \hat{\mathbf{w}} = X^T \mathbf{y}$$

进而推出线性回归模型的封闭解如下:

$$\hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$$

15. 在线性回归模型中, 假设输入样本记为 $\mathbf{x}_i, i = 1, \dots, N$, 相应的类别标签记为 $y_i, i = 1, \dots, N$ 。请给出自相关矩阵和互相关向量的定义 (公式与符号表达)。
如果样本集 $X \in \mathbb{R}^{N \times (d+1)}$ 中, $N < d + 1$, 应如何处理才能得到合理的模型参

数向量唯一解。

自相关矩阵记为 $R_x = X^T X$ ，其中 $X = \begin{bmatrix} \hat{\mathbf{x}}_1^T \\ \hat{\mathbf{x}}_2^T \\ \vdots \\ \hat{\mathbf{x}}_N^T \end{bmatrix}$ ，

互相关向量记作 $X^T \mathbf{y}$ ，其中 $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$

当 $N < d + 1$ 时，可以通过增加正则化项——单位阵 $I \in \mathbb{R}^{(d+1) \times (d+1)}$ ，得到新的最小二乘解如下：

$$\hat{\mathbf{w}} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

16. 请从求解线性方程组的角度说明线性回归模型的无解情况，从矩阵运算角度说明线性回归模型时的唯一解情况，并比较两者之间的联系与区别。

答：

(1) 线性回归模型，相当于求 $\mathbf{y} = \hat{\mathbf{w}}^T \hat{\mathbf{x}}$ ，即求下列方程组的解

$$\begin{cases} w_1 x_1^{(1)} + w_2 x_2^{(1)} + \cdots + w_d x_d^{(1)} + w_0 = y^{(1)} \\ w_1 x_1^{(2)} + w_2 x_2^{(2)} + \cdots + w_d x_d^{(2)} + w_0 = y^{(2)} \\ \vdots \\ w_1 x_1^{(N)} + w_2 x_2^{(N)} + \cdots + w_d x_d^{(N)} + w_0 = y^{(N)} \end{cases}$$

上述方程组共 N 个方程， $d+1$ 个未知数。在所有样本线性不相关的假设下，当 $d + 1 < N$ 时，方程组无解。

(2) 从矩阵运算的角度看，线性回归模型的解为 $\hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$ ，当 $d+1 \leq N$ 时，矩阵 $X^T X$ 满秩，存在唯一解。

(3) 两者的差别在于当 $d + 1 = N$ 时，方程组存在唯一解；当 $d + 1 < N$ 时，矩阵运算虽然得到了唯一解，但该唯一解是使得代价函数最小的解而非使得代价函数为 0 的解，因此无法使得方程组成立，因此对于方程组来说此时仍然无解。

17. 标签 y 是一个随机变量，由函数 $\hat{\mathbf{w}}^T \hat{\mathbf{x}}$ 加上一个随机噪声生成： $y = \hat{\mathbf{w}}^T \hat{\mathbf{x}} + \epsilon$ ；其中噪声 ϵ 服从正态分布 $\mathcal{N}(0, \sigma^2)$ ，设当前训练样本集为 $X = \{\hat{\mathbf{x}}_i | i = 1, \dots, N\}$, $Y = \{y_i | i = 1, \dots, N\}$ ；

(1) 试推导 $\hat{\mathbf{w}}$ 的最大似然解的数学形式；

答：根据定义，有 $\epsilon = y - \hat{\mathbf{w}}^T \hat{\mathbf{x}} \sim \mathcal{N}(0, \sigma^2)$ ，其似然性函数为：

$$p(\mathbf{x}; \delta^2, \hat{\mathbf{w}}) = \frac{1}{\sqrt{2\pi\delta^2}} \exp\left(-\frac{(y - \hat{\mathbf{w}}^T \hat{\mathbf{x}})^2}{2\delta^2}\right)$$

对于当前数据集 X 的整体对数似然性函数可以写为：

$$\begin{aligned} LL(X; \delta^2, \hat{\mathbf{w}}) &= \sum_{i=1}^N \ln\left(\frac{1}{\sqrt{2\pi\delta^2}} \exp\left(-\frac{(y_i - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i)^2}{2\delta^2}\right)\right) \\ &= \sum_i \left(\frac{(y - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i)^2}{2\delta^2} - \frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \delta^2 \right) \end{aligned}$$

则线性回归参数 $\hat{\mathbf{w}}$ 的估计问题转化为以下优化问题：

$$\hat{\mathbf{w}}^* = \underset{\hat{\mathbf{w}}}{\operatorname{argmax}} (LL(X; \delta^2, \hat{\mathbf{w}}))$$

令对数似然函数对线性回归函数的参数 $\hat{\mathbf{w}}$ 求导为 0，则有：

$$\begin{aligned} \frac{\partial LL(X; \delta^2, \hat{\mathbf{w}})}{\partial \hat{\mathbf{w}}} &= \sum_{i=1}^N \left(\frac{(y_i - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i) \hat{\mathbf{x}}_i}{\delta^2} \right) = 0 \\ \sum_{i=1}^N ((y_i - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i) \hat{\mathbf{x}}_i) &= 0 \\ \left[\sum_{i=1}^N \hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^T \right] \hat{\mathbf{w}} &= \sum_{i=1}^N \hat{\mathbf{x}}_i y_i \\ \hat{\mathbf{w}} &= (X^T X)^{-1} X^T \mathbf{y} \end{aligned}$$

(2) 假设 $\hat{\mathbf{w}}$ 的先验分布服从 $d+1$ 元正态分布 $\mathcal{N}(\mathbf{0}, I_{(d+1) \times (d+1)})$ ，试采用最大后验概率估计法推导 $\hat{\mathbf{w}}$ 的最优解的数学形式。

答：根据最大后验概率估计的定义，则目标函数可以写为：

$$J(X; \delta^2, \hat{\mathbf{w}}) = \sum_{i=1}^N \ln\left(\frac{1}{\sqrt{2\pi\delta^2}} \exp\left(-\frac{(y_i - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i)^2}{2\delta^2}\right)\right) + \ln\left(\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\hat{\mathbf{w}}^T \hat{\mathbf{w}}}{2}\right)\right)$$

则目标函数导数为 0 的方程为：

$$\begin{aligned} \frac{\partial J(X; \delta^2, \hat{\mathbf{w}})}{\partial \hat{\mathbf{w}}} &= \sum_{i=1}^N \left(\frac{(y_i - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i) \hat{\mathbf{x}}_i}{\delta^2} + \hat{\mathbf{w}} \right) = 0 \\ \sum_{i=1}^N ((y_i - \hat{\mathbf{w}}^T \hat{\mathbf{x}}_i) \hat{\mathbf{x}}_i + \delta^2 \hat{\mathbf{w}}) &= 0 \\ \left[\sum_{i=1}^N (\hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^T + \delta^2 I) \right] \hat{\mathbf{w}} &= \sum_{i=1}^N \hat{\mathbf{x}}_i y_i \\ \hat{\mathbf{w}} &= (X^T X + N\delta^2 I)^{-1} X^T \mathbf{y} \end{aligned}$$

令 $N\delta^2 = \lambda$ ，则有

$$\hat{\mathbf{w}} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

18. 如何防止线性回归模型出现过拟合现象，请给出具体的方案

答:在均方误差目标函数中加入正则化项 $\lambda\|\hat{\mathbf{w}}\|^2$,从而使得封闭解形式转为:

$$\hat{\mathbf{w}} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

上述方法使得当样本数量 N 小于参数维度 $d + 1$ 导致的过拟合现象,同时保证矩阵求逆有唯一解。

19. 请给出逻辑回归模型中 sigmoid 函数形式的推导过程,并说明其概率解释。

假设有一个二分类问题,后验概率: $P(\omega_1|\mathbf{x}) = y$, $P(\omega_2|\mathbf{x}) = 1 - y$

根据贝叶斯公式,有:

$$y = P(\omega_1|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_1)P(\omega_1)}{P(\mathbf{x})}, \quad 1 - y = P(\omega_2|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_2)P(\omega_2)}{P(\mathbf{x})}$$

则根据最大后验概率分类准则,判别函数为:

$$\ln \frac{y}{1 - y} = \ln \frac{P(\mathbf{x}|\omega_1)P(\omega_1)}{P(\mathbf{x}|\omega_2)P(\omega_2)}$$

假设两类样本服从正态分布: $\omega_1 \sim \mathcal{N}(\boldsymbol{\mu}_1, \Sigma_1)$, $\omega_2 \sim \mathcal{N}(\boldsymbol{\mu}_2, \Sigma_2)$

$$p(\mathbf{x}|\omega_i) = \frac{1}{2\pi^{\frac{l}{2}}|\Sigma_i|^{\frac{1}{2}}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) \right]$$

假设两类具有相同的先验概率和协方差矩阵: $P(\omega_1) = P(\omega_2)$, $\Sigma_1 = \Sigma_2 = \Sigma$

可以推出:

$$\ln \frac{y}{1 - y} = \ln P(\mathbf{x}|\omega_1) - \ln P(\mathbf{x}|\omega_2) = \mathbf{w}^T \mathbf{x} + w_0 = \hat{\mathbf{w}}^T \hat{\mathbf{x}}$$

其中: $\mathbf{w} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$, $w_0 = -\frac{1}{2}(\boldsymbol{\mu}_1^T \Sigma^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \Sigma^{-1} \boldsymbol{\mu}_2)$

进一步化简,可以得到:

$$\ln \frac{y}{1 - y} = \hat{\mathbf{w}}^T \hat{\mathbf{x}} \Rightarrow y = \frac{1}{1 + e^{-\hat{\mathbf{w}}^T \hat{\mathbf{x}}}} = P(\omega_1|\mathbf{x})$$

基于上述推导,可以看出逻辑回归函数是样本 \mathbf{x} 在具有相同先验概率和协方差矩阵的正态分布假设下从属于 ω_1 类的后验概率。

20. 请给出逻辑回归模型梯度下降法更新公式的推导过程。

答：逻辑回归函数是一种判别模型，可以视为寻找一组参数，使得后验概率最大化。后验概率原始形式为：

$$P(\boldsymbol{\theta}|\mathbf{x}) = \begin{cases} P(\omega_1|\mathbf{x}) & y = 1 \\ 1 - P(\omega_1|\mathbf{x}) & y = 0 \end{cases}$$

上式等价于：

$$\ln P(\boldsymbol{\theta}|\mathbf{x}) = y \ln P(\omega_1|\mathbf{x}) + (1 - y) \ln(1 - P(\omega_1|\mathbf{x}))$$

根据逻辑回归函数定义：

$$P(\omega_1|\mathbf{x}) = h(x) = \frac{1}{1 + e^{-\hat{\mathbf{w}}^T \hat{\mathbf{x}}}}$$

带入上式，将后验概率最大化问题转化为目标函数 $J(\hat{\mathbf{w}})$ 的最小化问题：

$$\begin{aligned} J(\hat{\mathbf{w}}) &= -\sum_{\mathbf{x} \in X} (y \ln P(\omega_1|\mathbf{x}) + (1 - y) \ln(1 - P(\omega_1|\mathbf{x}))) \\ &= -\sum_{\mathbf{x} \in X} \left(y \ln \frac{1}{1 + \exp(-\hat{\mathbf{w}}^T \hat{\mathbf{x}})} + (1 - y) \ln \left(\frac{\exp(-\hat{\mathbf{w}}^T \hat{\mathbf{x}})}{1 + \exp(-\hat{\mathbf{w}}^T \hat{\mathbf{x}})} \right) \right) \\ &= -\sum_{\mathbf{x} \in X} (y \ln[h(x)] + (1 - y) \ln[h(x)] + (1 - y)(-\hat{\mathbf{w}}^T \hat{\mathbf{x}})) \\ &= -\sum_{\mathbf{x} \in X} \left(\ln \left[\frac{\exp(\hat{\mathbf{w}}^T \hat{\mathbf{x}})}{1 + \exp(\hat{\mathbf{w}}^T \hat{\mathbf{x}})} \right] + (1 - y)(-\hat{\mathbf{w}}^T \hat{\mathbf{x}}) \right) \\ &= -\sum_{\mathbf{x} \in X} (-\ln[1 + \exp(\hat{\mathbf{w}}^T \hat{\mathbf{x}})] + \hat{\mathbf{w}}^T \hat{\mathbf{x}} + (1 - y)(-\hat{\mathbf{w}}^T \hat{\mathbf{x}})) \\ &= \sum_{\mathbf{x} \in X} (-y \hat{\mathbf{w}}^T \hat{\mathbf{x}} + \ln(1 + \exp(\hat{\mathbf{w}}^T \hat{\mathbf{x}}))) \end{aligned}$$

利用梯度下降法，先求 $J(\hat{\mathbf{w}})$ 的导数：

$$\begin{aligned} \frac{\partial J(\hat{\mathbf{w}})}{\partial \hat{\mathbf{w}}} &= \sum_{\mathbf{x} \in X} \left(-y \hat{\mathbf{x}} + \frac{\exp(\hat{\mathbf{w}}^T \hat{\mathbf{x}}) \hat{\mathbf{x}}}{1 + \exp(\hat{\mathbf{w}}^T \hat{\mathbf{x}})} \right) \\ &= \sum_{\mathbf{x} \in X} \left(\frac{1}{1 + \exp(-\hat{\mathbf{w}}^T \hat{\mathbf{x}})} - y \right) \hat{\mathbf{x}} \\ &= \sum_{\mathbf{x} \in X} (h(x) - y) \hat{\mathbf{x}} \end{aligned}$$

最后的梯度下降法更新公式：

$$\hat{\mathbf{w}}(t + 1) = \hat{\mathbf{w}}(t) - \rho \sum_{\mathbf{x} \in X} (h(\mathbf{x}; \hat{\mathbf{w}}(t)) - y) \hat{\mathbf{x}}$$

五、计算（画图）题

21. 已知两个类别 ω_1 和 ω_2 ，其先验概率相等，两类的类条件概率密度服从正态分布，有 $p(\mathbf{x}|\omega_1) = \mathcal{N}(\mu_1, \Sigma)$ 和 $p(\mathbf{x}|\omega_2) = \mathcal{N}(\mu_2, \Sigma)$ ，且 $\mu_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ， $\mu_2 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$ ，

$\Sigma = \begin{bmatrix} 1.1 & 0.3 \\ 0.3 & 1.9 \end{bmatrix}$, 试写出上述问题每一类的判别函数 $g_i(\mathbf{x})$, $i = 1, 2$ 的线性形式以及整个分类问题的决策面方程的线性形式。并判断样本 $\mathbf{x} = \begin{bmatrix} 1.2 \\ 1.9 \end{bmatrix}$ 属于哪一类, 给出计算过程。

答: 判别函数是后验概率的某种单调递增函数, 考虑到两类服从高斯分布。可以首先使用后验概率的对数函数作为初始的判别函数:

$$g_i(\mathbf{x}) = \ln(P(\omega_i|\mathbf{x})) = \ln\left(\frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{P(\mathbf{x})}\right)$$

题中条件先验概率相等, 边缘概率 $P(\mathbf{x})$ 不改变两类之间的相对大小, 因此可以简化为:

$$\begin{aligned} g_i(\mathbf{x}) &= \ln(P(\mathbf{x}|\omega_i)) \\ &= \ln\left(\frac{1}{2\pi|\Sigma|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)\right]\right) \end{aligned}$$

考虑到两类的协方差矩阵相等, 可以去除包含协方差 Σ 的常数项和二次项, 得到:

$$g_i(\mathbf{x}) = \boldsymbol{\mu}_i^T \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i$$

已知: $\Sigma = \begin{bmatrix} 1.1 & 0.3 \\ 0.3 & 1.9 \end{bmatrix}$, 可以求得 $\Sigma^{-1} = \begin{bmatrix} 0.95 & -0.15 \\ -0.15 & 0.55 \end{bmatrix}$, 带入均值向量 $\boldsymbol{\mu}_i$ 得:

$$\begin{aligned} g_1(\mathbf{x}) &= 0 \\ g_2(\mathbf{x}) &= 2.4x_1 + 1.2x_2 - 5.4 \end{aligned}$$

决策面方程为:

$$g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) = 0$$

推出决策面方程为:

$$-4x_1 - 2x_2 + 9 = 0$$

将样本 $\mathbf{x} = \begin{bmatrix} 1.2 \\ 1.9 \end{bmatrix}$, 带入决策面方程等号右侧得到 $0.4 > 0$, 因此为 ω_1 类


22. 已知决策面方程: $5x_1 - x_2 - 1 = 0$, 当前错分样本为: $(0.4, 0.6)$, $(0.1 - 0.25)$ 。

- (1) 写出参数向量 w , 并设定合适的学习步长 η ;
- (2) 列出迭代公式和计算结果
- (3) 列出迭代后的决策面方程
- (4) 画出相应的决策面 (虚线)
- (5) 给出结论与分析

$$(1) \mathbf{w} = \begin{bmatrix} 5 \\ -1 \\ -1 \end{bmatrix}, \eta = 0.9$$

$$(2) \hat{\mathbf{w}}(t+1) = \begin{bmatrix} 5 \\ -1 \\ -1 \end{bmatrix} - 0.9(+1) \begin{bmatrix} 0.4 \\ 0.6 \\ 1 \end{bmatrix} - 0.9(-1) \begin{bmatrix} 0.1 \\ -0.3 \\ 1 \end{bmatrix} = \begin{bmatrix} 4.73 \\ -1.81 \\ -1 \end{bmatrix}$$

(3) 迭代后的决策面方程: $4.73x_1 - 1.81x_2 - 1 = 0$



(4) 通过梯度下降法, 经过一次迭代, 决策面的位置发生了变化。将两个错分样本(0.4,0.6), (0.1-0.25)分别代入新的决策面方程, 可以发现分类结果正确, 说明感知器算法实现了对决策面的优化, 提升了在训练集上的正确率。

23. 以 Iris 数据库每类的 70% 的样本为训练集, 基于线性回归模型, 使用花萼长度、花萼宽度和花瓣宽度特征来估计其花瓣长度特征, 请写出线性回归模型参数的封闭解的数学形式, 标明每个变量的矩阵大小或矢量维度。

24. 已知 3 个样本坐标为 $\mathbf{x}^{(1)} = [1,0], \mathbf{x}^{(2)} = [0,1], \mathbf{x}^{(3)} = [1,1]$, 其中 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in \omega_1, \mathbf{x}^{(3)} \in \omega_2$, 初始化逻辑回归模型对应的线性决策面为: $x_1 = 0.5$ 。设学习步长为 0.2。请计算基于逻辑回归梯度下降法进行一次迭代后的决策面方程, 并在下图中画出相应的决策面直线。

根据题意, 定义以下变量并且初始化:

步长: $\rho = 0.2$

模型参数: $\hat{\mathbf{w}} = [w_1, w_2, w_0] = [1, 0, -0.5]$

标签: $\mathbf{y} = [1, 1, 0]^T$

训练样本: $\hat{\mathbf{x}}^{(1)} = [1, 0, 1], \hat{\mathbf{x}}^{(2)} = [0, 1, 1], \hat{\mathbf{x}}^{(3)} = [1, 1, 1]$

计算梯度:

$$\begin{aligned}\frac{\partial J(\hat{\mathbf{w}})}{\partial \hat{\mathbf{w}}} &= \frac{1}{M} \sum_{i=1}^M (h(\hat{\mathbf{x}}^{(i)}) - y^{(i)}) \hat{\mathbf{x}}^{(i)} \\ &= \frac{1}{3} \left\{ \left(\frac{1}{1 + e^{-[1, 0, -0.5][1, 0, 1]^T}} - 1 \right) \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + \left(\frac{1}{1 + e^{-[1, 0, -0.5][0, 1, 1]^T}} - 1 \right) \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \right. \\ &\quad \left. + \left(\frac{1}{1 + e^{-[1, 0, -0.5][1, 1, 1]^T}} - 0 \right) \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\} \\ &= [0.082, 0, -0.13]^T\end{aligned}$$

更新模型参数:

$$\hat{\mathbf{w}}^{(1)} = \hat{\mathbf{w}}^{(0)} - \rho \frac{\partial J(\hat{\mathbf{w}})}{\partial \hat{\mathbf{w}}} = \begin{bmatrix} 1 \\ 0 \\ -0.5 \end{bmatrix} - 0.2 \times \begin{bmatrix} 0.082 \\ 0 \\ -0.13 \end{bmatrix} = \begin{bmatrix} 0.98 \\ 0 \\ -0.47 \end{bmatrix}$$

迭代一次后的决策面方程为:

$$\begin{aligned}0.98x_1 - 0.47 &= 0 \\ x_1 &= 0.48\end{aligned}$$

